Защищено:
Гапанюк Ю.Е.

"__"_____2022 г.

Демонстрация:
Гапанюк Ю.Е.

"__"_____2022 г.

Отчет по лабораторной работе № 2 по курсу Технологии машинного обучения ГУИМЦ

Тема работы: " Обработка пропусков в данных, кодирование категориальных признаков, масштабирование данных. "

13
(количество листов)
Вариант № **3**

ИСПОЛНИТЕЛЬ:

студент группы ИУ5Ц-82Б _____
(подпись)

Чиварзин А.Е.

"__"_____2022 г.

Москва, МГТУ - 2022

Цель лабораторной работы

Изучение способов предварительной обработки данных для дальнейшего формирования моделей.

Задание

1. Выбрать набор данных (датасет), содержащий категориальные признаки и пропуски в данных. Для выполнения следующих пунктов можно использовать несколько различных наборов данных (один для обработки пропусков, другой для категориальных признаков и т.д.)
2. Для выбранного датасета (датасетов) на основе материалов лекции решить следующие задачи:
   - обработку пропусков в данных;
   - кодирование категориальных признаков;
   - масштабирование данных.

Ход выполнения работы

Текстовое описание набора данных

В качестве набора данных используется **dataset** рейтингов университетов мира на основании трёх рейтингов. Датасет доступен по адресу: https://www.kaggle.com/mylesoneill/world-university-rankings

Из набора данных будет рассматриваться только файл `cwurData.csv`.

Описание столбцов:

- `world_rank` - мировой рейтинг университета
- `institution` - название университета
- `country` - страна, в которой расположен университет
- `national_rank` - рейтинг университета в стране его нахождения
- `quality_of_education` - рейтинг качества образования
- `quality_of_faculty` - рейтинг качества профессорско-преподавательского состава
- `publications` - рейтинг публикаций
- `infuence` - рейтинг влияния
- `citations` - количество студентов в университете
- `broad_impact` - рейтинг за широкое влияние (предоставлен только за **2014** и **2015** гг. Остальное - пропуски)
- `patents` - рейтинг за патенты
- `score` - общий балл, используемый для определения мирового рейтинга
- `year` - год рейтинга (с **2012** по **2015** год)

Основные характеристики набора данных

Подключаем все необходимые библиотеки

In [1]:

```
import numpy as np
import pandas as pd
import seaborn as sns
import matplotlib
import matplotlib_inline
```

```
import matplotlib.pyplot as plt
%matplotlib inline
sns.set(style="ticks")
```

Подключаем **Dataset**

In [2]:

```
data = pd.read_csv('cwurData.csv', sep=",")
```

Размер набора данных

In [3]:

```
data.shape
```

Out[3]:

```
(2200, 14)
```

Типы колонок

In [4]:

```
data.dtypes
```

Out[4]:

```
world_rank              int64
institution            object
country                object
national_rank           int64
quality_of_education    int64
alumni_employment       int64
quality_of_faculty      int64
publications            int64
influence               int64
citations               int64
broad_impact          float64
patents                 int64
score                 float64
year                    int64
dtype: object
```

Проверяем, есть ли пропущенные значения

In [5]:

```
data.isnull().sum()
```

Out[5]:

```
world_rank              0
institution             0
country                 0
national_rank           0
quality_of_education    0
alumni_employment       0
quality_of_faculty      0
publications            0
influence               0
citations               0
broad_impact          200
patents                 0
score                   0
year                    0
dtype: int64
```

Первые **5** строк датасета

In [6]:

```
data.head()
```

Out[6]:

	world_rank	institution	country	national_rank	quality_of_education	alumni_employment	quality_of_faculty	publications
0	1	Harvard University	USA	1	7	9	1	1
1	2	Massachusetts Institute of Technology	USA	2	9	17	3	12
2	3	Stanford University	USA	3	17	11	5	4
3	4	University of Cambridge	United Kingdom	1	10	24	4	16
4	5	California Institute of Technology	USA	4	2	29	7	37

In [7]:

```
total_count = data.shape[0]
print('Всего строк: {}'.format(total_count))
```

```
Всего строк: 2200
```

Процент пропусков в `broad_impact`

In [8]:

```
(200 / 2200) * 100
```

Out[8]:

```
9.090909090909092
```

Настройка отображения графиков

In [9]:

```
# Задание формата графиков для сохранения высокого качества PNG
from IPython.display import set_matplotlib_formats
matplotlib_inline.backend_inline.set_matplotlib_formats("retina")
# Задание ширины графиков, чтобы они помещались на A4
```

Обработка пропусков данных

Очистка строк

Можно очистить строки, содержащие пропуски. При этом останутся данные только за **2014** и **2015** гг (см. описание датасета)

In [10]:

```
# Удаление строк, содержащих пустые значения
data_no_null = data.dropna(axis=0, how='any')
(data.shape, data_no_null.shape)
```

Out[10]:

```
((2200, 14), (2000, 14))
```

Выведем первые **11** строк, чтобы убедиться, что данные в `national_rank` числовые **(Jupyter Lab** в предпросмотре **CSV** показывает не совсем верно**)**

In [11]:

```
data_no_null.head(11)
```

Out[11]:

	world_rank	institution	country	national_rank	quality_of_education	alumni_employment	quality_of_faculty	publicatio
200	**1**	**Harvard University**	**USA**	**1**	**1**	**1**	**1**	
201	**2**	**Stanford University**	**USA**	**2**	**11**	**2**	**4**	
202	**3**	**Massachusetts Institute of Technology**	**USA**	**3**	**3**	**11**	**2**	
203	**4**	**University of Cambridge**	**United Kingdom**	**1**	**2**	**10**	**5**	
204	**5**	**University of Oxford**	**United Kingdom**	**2**	**7**	**12**	**10**	
205	**6**	**Columbia University**	**USA**	**4**	**13**	**8**	**9**	
206	**7**	**University of California, Berkeley**	**USA**	**5**	**4**	**22**	**6**	
207	**8**	**University of Chicago**	**USA**	**6**	**10**	**14**	**8**	
208	**9**	**Princeton University**	**USA**	**7**	**5**	**16**	**3**	
209	**10**	**Yale University**	**USA**	**8**	**9**	**25**	**11**	
210	**11**	**Cornell University**	**USA**	**9**	**12**	**18**	**19**	

In [12]:

```
total_count = data_no_null.shape[0]
print('Всего строк: {}'.format(total_count))
```

```
Всего строк: 2000
```

Внедрение значений

In [13]:

```
# Выберем числовые колонки с пропущенными значениями
# Цикл по колонкам датасета
num_cols = []
for col in data.columns:
    # Количество пустых значений
    temp_null_count = data[data[col].isnull()].shape[0]
    dt = str(data[col].dtype)
    if temp_null_count>0 and (dt=='float64' or dt=='int64'):
        num_cols.append(col)
        temp_perc = round((temp_null_count / total_count) * 100.0, 2)
        print('Колонка {}. Тип данных {}. Количество пустых значений {}, {}%.'.format(col
, dt, temp_null_count, temp_perc))
```

```
Колонка broad_impact. Тип данных float64. Количество пустых значений 200, 10.0%.
```

In [33]:

```
# Фильтр по колонкам с пропущенными значениями
```

```
# Фильтр по колонкам с пропущенными значениями
data_num = data[num_cols]
data_num
```

Out[33]:

	broad_impact
0	NaN
1	NaN
2	NaN
3	NaN
4	NaN
...	...
2195	969.0
2196	981.0
2197	975.0
2198	975.0
2199	981.0

2200 rows × 1 columns

In [34]:

```
# Гистограмма по признакам
for col in data_num:
    plt.hist(data[col], 50)
    plt.xlabel(col)
    plt.show()
```

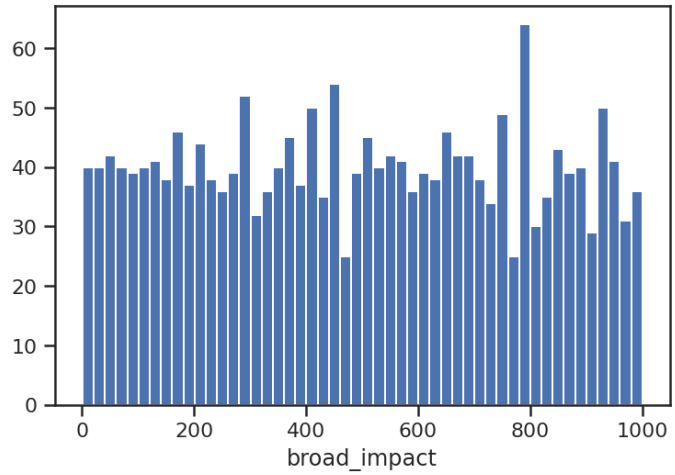

Будем использовать встроенные средства импьютации библиотеки **scikit-learn** - https://scikit-learn.org/stable/modules/impute.html

In [35]:

```
data_num_MasVnrArea = data_num[['broad_impact']]
data_num_MasVnrArea.head()
```

Out[35]:

	broad_impact
0	NaN
1	NaN
2	NaN
3	NaN
4	NaN

```
4              NaN
    broad_impact
```

In [36]:

```
from sklearn.impute import SimpleImputer
from sklearn.impute import MissingIndicator
```

In [37]:

```
# Фильтр для проверки заполнения пустых значений
indicator = MissingIndicator()
mask_missing_values_only = indicator.fit_transform(data_num_MasVnrArea)
mask_missing_values_only
```

Out[37]:

```
array([[ True],
       [ True],
       [ True],
       ...,
       [False],
       [False],
       [False]])
```

С помощью класса **SimpleImputer** проверим импьютацию различными показателями центра распределения

In [38]:

```
strategies=['mean', 'median', 'most_frequent']
```

In [39]:

```
def test_num_impute(strategy_param):
    imp_num = SimpleImputer(strategy=strategy_param)
    data_num_imp = imp_num.fit_transform(data_num_MasVnrArea)
    return data_num_imp[mask_missing_values_only]
```

In [40]:

```
strategies[0], test_num_impute(strategies[0])
```

Out[40]:

```
('mean',
 array([496.6995, 496.6995, 496.6995, 496.6995, 496.6995, 496.6995,
        496.6995, 496.6995, 496.6995, 496.6995, 496.6995, 496.6995,
        496.6995, 496.6995, 496.6995, 496.6995, 496.6995, 496.6995,
        496.6995, 496.6995, 496.6995, 496.6995, 496.6995, 496.6995,
        496.6995, 496.6995, 496.6995, 496.6995, 496.6995, 496.6995,
        496.6995, 496.6995, 496.6995, 496.6995, 496.6995, 496.6995,
        496.6995, 496.6995, 496.6995, 496.6995, 496.6995, 496.6995,
        496.6995, 496.6995, 496.6995, 496.6995, 496.6995, 496.6995,
        496.6995, 496.6995, 496.6995, 496.6995, 496.6995, 496.6995,
        496.6995, 496.6995, 496.6995, 496.6995, 496.6995, 496.6995,
        496.6995, 496.6995, 496.6995, 496.6995, 496.6995, 496.6995,
        496.6995, 496.6995, 496.6995, 496.6995, 496.6995, 496.6995,
        496.6995, 496.6995, 496.6995, 496.6995, 496.6995, 496.6995,
        496.6995, 496.6995, 496.6995, 496.6995, 496.6995, 496.6995,
        496.6995, 496.6995, 496.6995, 496.6995, 496.6995, 496.6995,
        496.6995, 496.6995, 496.6995, 496.6995, 496.6995, 496.6995,
        496.6995, 496.6995, 496.6995, 496.6995, 496.6995, 496.6995,
        496.6995, 496.6995, 496.6995, 496.6995, 496.6995, 496.6995,
        496.6995, 496.6995, 496.6995, 496.6995, 496.6995, 496.6995,
        496.6995, 496.6995, 496.6995, 496.6995, 496.6995, 496.6995,
        496.6995, 496.6995, 496.6995, 496.6995, 496.6995, 496.6995,
        496.6995, 496.6995, 496.6995, 496.6995, 496.6995, 496.6995,
        496.6995, 496.6995, 496.6995, 496.6995, 496.6995, 496.6995,
        496.6995, 496.6995, 496.6995, 496.6995, 496.6995, 496.6995,
        496.6995, 496.6995, 496.6995, 496.6995, 496.6995, 496.6995,
        496.6995, 496.6995, 496.6995, 496.6995, 496.6995, 496.6995,
        496.6995, 496.6995, 496.6995, 496.6995, 496.6995, 496.6995,
        496.6995, 496.6995, 496.6995, 496.6995, 496.6995, 496.6995,
```

```
       496.6995, 496.6995, 496.6995, 496.6995, 496.6995, 496.6995,
       496.6995, 496.6995, 496.6995, 496.6995, 496.6995, 496.6995,
       496.6995, 496.6995, 496.6995, 496.6995, 496.6995, 496.6995,
       496.6995, 496.6995, 496.6995, 496.6995, 496.6995, 496.6995,
       496.6995, 496.6995, 496.6995, 496.6995, 496.6995, 496.6995,
       496.6995, 496.6995]))
```

In [41]:

```
strategies[1], test_num_impute(strategies[1])
```

Out[41]:

```
('median',
 array([496., 496., 496., 496., 496., 496., 496., 496., 496., 496., 496.,
       496., 496., 496., 496., 496., 496., 496., 496., 496., 496., 496.,
       496., 496., 496., 496., 496., 496., 496., 496., 496., 496., 496.,
       496., 496., 496., 496., 496., 496., 496., 496., 496., 496., 496.,
       496., 496., 496., 496., 496., 496., 496., 496., 496., 496., 496.,
       496., 496., 496., 496., 496., 496., 496., 496., 496., 496., 496.,
       496., 496., 496., 496., 496., 496., 496., 496., 496., 496., 496.,
       496., 496., 496., 496., 496., 496., 496., 496., 496., 496., 496.,
       496., 496., 496., 496., 496., 496., 496., 496., 496., 496., 496.,
       496., 496., 496., 496., 496., 496., 496., 496., 496., 496., 496.,
       496., 496., 496., 496., 496., 496., 496., 496., 496., 496., 496.,
       496., 496., 496., 496., 496., 496., 496., 496., 496., 496., 496.,
       496., 496., 496., 496., 496., 496., 496., 496., 496., 496., 496.,
       496., 496., 496., 496., 496., 496., 496., 496., 496., 496., 496.,
       496., 496., 496., 496., 496., 496., 496., 496., 496., 496., 496.,
       496., 496., 496., 496., 496., 496., 496., 496., 496., 496., 496.,
       496., 496., 496., 496., 496., 496., 496., 496., 496., 496., 496.,
       496., 496., 496., 496., 496., 496., 496., 496., 496., 496., 496.,
       496., 496.]))
```

In [42]:

```
strategies[2], test_num_impute(strategies[2])
```

Out[42]:

```
('most_frequent',
 array([642., 642., 642., 642., 642., 642., 642., 642., 642., 642., 642.,
       642., 642., 642., 642., 642., 642., 642., 642., 642., 642., 642.,
       642., 642., 642., 642., 642., 642., 642., 642., 642., 642., 642.,
       642., 642., 642., 642., 642., 642., 642., 642., 642., 642., 642.,
       642., 642., 642., 642., 642., 642., 642., 642., 642., 642., 642.,
       642., 642., 642., 642., 642., 642., 642., 642., 642., 642., 642.,
       642., 642., 642., 642., 642., 642., 642., 642., 642., 642., 642.,
       642., 642., 642., 642., 642., 642., 642., 642., 642., 642., 642.,
       642., 642., 642., 642., 642., 642., 642., 642., 642., 642., 642.,
       642., 642., 642., 642., 642., 642., 642., 642., 642., 642., 642.,
       642., 642., 642., 642., 642., 642., 642., 642., 642., 642., 642.,
       642., 642., 642., 642., 642., 642., 642., 642., 642., 642., 642.,
       642., 642., 642., 642., 642., 642., 642., 642., 642., 642., 642.,
       642., 642., 642., 642., 642., 642., 642., 642., 642., 642., 642.,
       642., 642., 642., 642., 642., 642., 642., 642., 642., 642., 642.,
       642., 642., 642., 642., 642., 642., 642., 642., 642., 642., 642.,
       642., 642., 642., 642., 642., 642., 642., 642., 642., 642., 642.,
       642., 642., 642., 642., 642., 642., 642., 642., 642., 642., 642.,
       642., 642.]))
```

In [43]:

```
# Более сложная функция, которая позволяет задавать колонку и вид импьютации
def test_num_impute_col(dataset, column, strategy_param):
    temp_data = dataset[[column]]

    indicator = MissingIndicator()
    mask_missing_values_only = indicator.fit_transform(temp_data)

    imp_num = SimpleImputer(strategy=strategy_param)
    data_num_imp = imp_num.fit_transform(temp_data)
```

```
    filled_data = data_num_imp[mask_missing_values_only]

    return column, strategy_param, filled_data.size, filled_data[0], filled_data[filled_d
ata.size-1]
```

In [44]:

```
data[['broad_impact']].describe()
```

Out[44]:

	broad_impact
count	**2000.000000**
mean	**496.699500**
std	**286.919755**
min	**1.000000**
25%	**250.500000**
50%	**496.000000**
75%	**741.000000**
max	**1000.000000**

In [47]:

```
test_num_impute_col(data, 'broad_impact', strategies[0])
```

Out[47]:

```
('broad_impact', 'mean', 200, 496.6995, 496.6995)
```

In [48]:

```
test_num_impute_col(data, 'broad_impact', strategies[1])
```

Out[48]:

```
('broad_impact', 'median', 200, 496.0, 496.0)
```

In [50]:

```
test_num_impute_col(data, 'broad_impact', strategies[2])
```

Out[50]:

```
('broad_impact', 'most_frequent', 200, 642.0, 642.0)
```

Кодирование категориальных признаков

Преобразуем названия стран, городов, **...** в числовые зеачения **(label encoding)**

In [14]:

```
from sklearn.preprocessing import LabelEncoder, OneHotEncoder
```

======> `institution` **<==========**

In [15]:

```
le = LabelEncoder()
institution_le = le.fit_transform(data_no_null['institution'])
```

In [16]:

```
data_no_null['institution'].unique()
```

Out[16]:

Out[16]:

```
array(['Harvard University', 'Stanford University',
       'Massachusetts Institute of Technology', ...,
       'Babeş-Bolyai University', 'Henan Normal University',
       'Southwest Jiaotong University'], dtype=object)
```

In [17]:

```
arr_institution_encoded = np.unique(institution_le)
arr_institution_encoded
```

Out[17]:

```
array([   0,    1,    2, ..., 1020, 1021, 1022])
```

In [18]:

```
le.inverse_transform([n for n in range(1023)])
```

Out[18]:

```
array(['AGH University of Science and Technology', 'Aalborg University',
       'Aalto University', ..., 'École normale supérieure de Cachan',
       'École normale supérieure de Lyon', 'Örebro University'],
      dtype=object)
```

======> `country` **<==========**

In [19]:

```
le_country = LabelEncoder()
country_le = le_country.fit_transform(data_no_null['country'])
```

In [20]:

```
data_no_null['country'].unique()
```

Out[20]:

```
array(['USA', 'United Kingdom', 'Japan', 'Switzerland', 'Israel',
       'South Korea', 'Canada', 'France', 'Russia', 'China', 'Taiwan',
       'Sweden', 'Singapore', 'Denmark', 'Germany', 'Netherlands',
       'Italy', 'Belgium', 'Australia', 'Finland', 'Norway',
       'South Africa', 'Spain', 'Brazil', 'Hong Kong', 'Ireland',
       'Austria', 'New Zealand', 'Portugal', 'Thailand', 'Czech Republic',
       'Malaysia', 'India', 'Greece', 'Mexico', 'Hungary', 'Argentina',
       'Turkey', 'Poland', 'Saudi Arabia', 'Chile', 'Iceland', 'Slovenia',
       'Estonia', 'Lebanon', 'Croatia', 'Colombia', 'Slovak Republic',
       'Iran', 'Egypt', 'Serbia', 'Bulgaria', 'Lithuania', 'Uganda',
       'United Arab Emirates', 'Uruguay', 'Cyprus', 'Romania',
       'Puerto Rico'], dtype=object)
```

In [21]:

```
np.unique(country_le)
```

Out[21]:

```
array([ 0,  1,  2,  3,  4,  5,  6,  7,  8,  9, 10, 11, 12, 13, 14, 15, 16,
       17, 18, 19, 20, 21, 22, 23, 24, 25, 26, 27, 28, 29, 30, 31, 32, 33,
       34, 35, 36, 37, 38, 39, 40, 41, 42, 43, 44, 45, 46, 47, 48, 49, 50,
       51, 52, 53, 54, 55, 56, 57, 58])
```

In [22]:

```
le_country.inverse_transform([n for n in range(59)])
```

Out[22]:

```
array(['Argentina', 'Australia', 'Austria', 'Belgium', 'Brazil',
       'Bulgaria', 'Canada', 'Chile', 'China', 'Colombia', 'Croatia',
       'Cyprus', 'Czech Republic', 'Denmark', 'Egypt', 'Estonia',
       'Finland', 'France', 'Germany', 'Greece', 'Hong Kong', 'Hungary',
```

```
       'Iceland', 'India', 'Iran', 'Ireland', 'Israel', 'Italy', 'Japan',
       'Lebanon', 'Lithuania', 'Malaysia', 'Mexico', 'Netherlands',
       'New Zealand', 'Norway', 'Poland', 'Portugal', 'Puerto Rico',
       'Romania', 'Russia', 'Saudi Arabia', 'Serbia', 'Singapore',
       'Slovak Republic', 'Slovenia', 'South Africa', 'South Korea',
       'Spain', 'Sweden', 'Switzerland', 'Taiwan', 'Thailand', 'Turkey',
       'USA', 'Uganda', 'United Arab Emirates', 'United Kingdom',
       'Uruguay'], dtype=object)
```

In [23]:

```
data_no_null.head()
```

Out[23]:

	world_rank	institution	country	national_rank	quality_of_education	alumni_employment	quality_of_faculty	publicatio
200	1	Harvard University	USA	1	1	1	1	
201	2	Stanford University	USA	2	11	2	4	
202	3	Massachusetts Institute of Technology	USA	3	3	11	2	
203	4	University of Cambridge	United Kingdom	1	2	10	5	
204	5	University of Oxford	United Kingdom	2	7	12	10	

In [24]:

```
data_digit = data_no_null.copy()
#data_digit.pop('institution')
#data_digit.pop('country')
data_digit["institution"] = institution_le
data_digit['country'] = country_le
data_digit
```

Out[24]:

	world_rank	institution	country	national_rank	quality_of_education	alumni_employment	quality_of_faculty	publications	i
200	1	184	54	1	1	1	1	1	
201	2	511	54	2	11	2	4	5	
202	3	312	54	3	3	11	2	15	
203	4	637	57	1	2	10	5	10	
204	5	819	57	2	7	12	10	11	
...	...	...	...	...	...	...	...	...	
2195	996	954	37	7	367	567	218	926	
2196	997	11	14	4	236	566	218	997	
2197	998	132	4	18	367	549	218	830	
2198	999	576	48	40	367	567	218	886	
2199	1000	74	8	83	367	567	218	861	

2000 rows × 14 columns

Проверяем типы данных

In [25]:

```
data_digit.dtypes
```

```
data_digit.dtypes
```

Out[25]:

```
world_rank                int64
institution               int64
country                   int64
national_rank             int64
quality_of_education      int64
alumni_employment         int64
quality_of_faculty        int64
publications              int64
influence                 int64
citations                 int64
broad_impact            float64
patents                   int64
score                   float64
year                      int64
dtype: object
```

Масштабирование данных

Масштабирование пудем проводить на `data_digit` **(где нет категориальных признаков)**

In [26]:

```
from sklearn.preprocessing import MinMaxScaler, StandardScaler, Normalizer
```

MinMax масштабирование

=====> `world_rank` **<=====**

In [27]:

```
sc1 = MinMaxScaler()
sc1_data = sc1.fit_transform(data_digit[['broad_impact']])
```

In [28]:

```
plt.hist(data_digit['broad_impact'], 50)
plt.show()
```

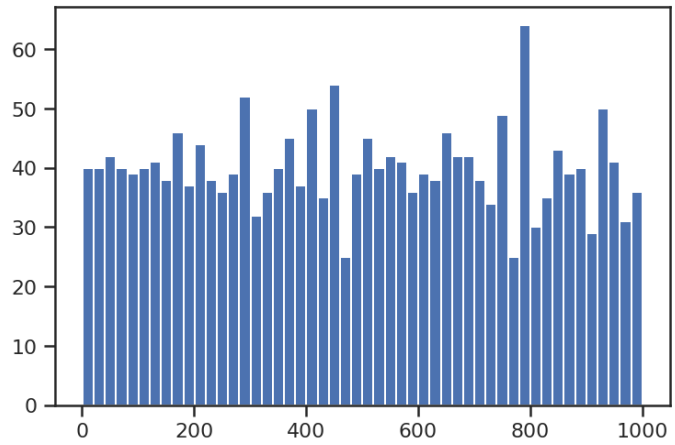

In [29]:

```
plt.hist(sc1_data, 50)
plt.show()
```

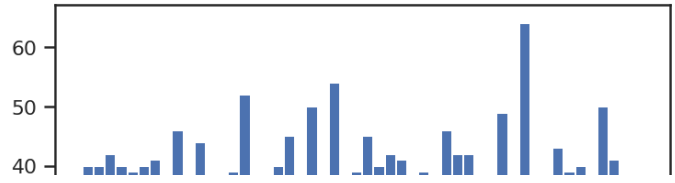

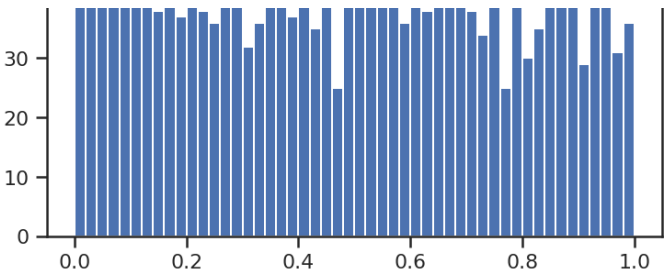

In [ ]:

```
```

Масштабирование данных на основе **Z**-оценки - **StandardScaler**

In [30]:

```
sc2 = StandardScaler()
sc2_data = sc2.fit_transform(data_digit[['broad_impact']])
```

In [31]:

```
plt.hist(sc2_data, 50)
plt.show()
```

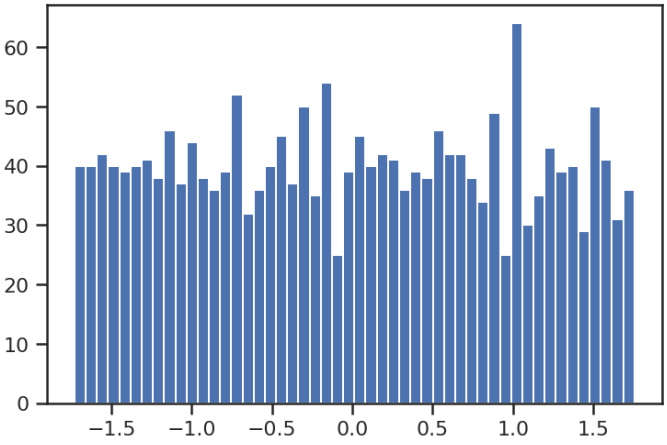

In [ ]:

```
```